

Walmart 구매 데이터 분석 보고서

가설 검정과 시각화를 통한 구매 패턴 분석

One Line Summary: 월마트 구매 데이터에서 도시 유형, 거주 기간, 제품 카테고리에 따라 구매금액 분포가 달라지는지를 가설 검정과 시각화로 확인했다.



분석 목표 (Analysis Goals)

1. 마스킹된 범주형 변수(도시/직업/카테고리)를 과해석하지 않고, 유형 간 차이 존재 여부를 확인한다.
2. 차이가 있더라도 그 크기가 실무적으로 의미 있는 수준인지 효과크기(Effect Size)까지 함께 본다.
3. 그래프는 장식이 아니라 근거로 사용하고, 각 결과는 문장으로 정리한다.



데이터 해석 주의 (Data Interpretation Cautions)

- City_Category, Occupation, Product_Category는 마스킹된 값이다.
- 따라서 'A'가 대도시 같은 구체적인 의미를 부여하지 않고, 유형(A/B/C) 간 차이로만 해석한다.

데이터 개요 및 전처리 (Data Overview & Preprocessing)



Data Overview	Data Overview
Source: Kaggle Walmart Dataset (550,068 rows, 10 columns).	JetBrains Mono
Key Columns: User_ID, Product_ID, Gender, Age, Occupation, City_Category, Stay_In_Current_City_Years, Marital_Status, Product_Category, Purchase.	

	총 거래 수	총 고객 수	총 상품 수	총 매출(합계 Purchase)	평균 구매금액	중앙값 구매금액
0	550068	5891	3631	5095812742	9263.968713	8047.0

Preprocessing Strategy (전처리)
- 숫자인 척하는 범주형: Occupation, Product_Category, Marital_Status → category type. - 순서형 범주(Ordered Category): Age ('0-17' to '55+'), Stay_In_Current_City_Years ('0' to '4+') → 정렬 순서 지정.


가설 1: 도시 유형(City Category)별 분포

City_Category(A/B/C) 유형에 따라 구매금액(Purchase) 분포는 차이가 있는가?



해석: Boxplot 기준 City C의 중앙값이 A/B보다 높게 나타난다. 동시에 세 유형의 분포는 겹치는 구간이 넓어서, 차이가 있더라도 큰 격차라고 단정하기는 어렵다.

가설 1 검증: 통계적 유의성 확인



Kruskal-Wallis Test Results	
검정	Kruskal-Wallis
p-value	0.0
효과크기(epsilon^2)	0.004184


결론: 통계적으로 차이는 확인되나, 효과크기가 매우 작아(0.004) 실무적으로 큰 격차로 단정하기보다 유형 간 패턴 차이가 존재한다는 수준으로 정리한다.

Post-hoc Analysis (Mann-Whitney U)		
A vs C	B vs C	A vs B
0.0032812	0.0041844	0.0003001


가설 2: 거주 기간(Stay Duration)별 분포

거주 기간(Stay_In_Current_City_Years)에 따라 구매금액(Purchase) 특성은 달라지는가?

거주 기간별 구매금액 분포 (boxplot)



거주 기간별 구매금액 분포 (표본 stripplot, n=5000)



해석:

거주 기간별 중앙값은 큰 폭으로
갈라지기보다는 비슷한 수준에서
소폭 변화하는 모습이다.

점들이 그룹별로 비슷하게 퍼져
있으며, 거주 기간만으로
구매금액이 크게 달라진다고
보기 어렵다.

가설 2 검증: 상관관계 및 효과크기



검정 결과 요약	
검정 (Test)	값 (Value)
Kruskal-Wallis Effect Size (ϵ^2)	0.000055
Spearman Rank Correlation (ρ)	0.005944
Levene Variance Test (p-value)	0.00004

결론

상관계수(ρ)가 0에 매우 가까우며, 거주 기간이 길어질수록 구매금액이 증가한다는 단조 경향은 약하다.
따라서 거주 기간은 단독 변수로 타겟팅 기준을 삼기보다는, 다른 요인과 결합해서 보조적으로 해석, 해석하는 편이 적절하다.

가설 3: 제품 카테고리별 인구통계 편중성


독립성 검정 (Independence Test)



결과: Chi-square p-value: 0.0 (유의함). 제품 카테고리별로 성별/연령 구성의 차이는 통계적으로 확인된다. 카테고리 운영 단위에서 메시지 톤이나 채널을 미세 조정하는 근거로 사용 가능하다.

보강 분석: 교차 세그먼트 (City x Product)

평균 구매금액 히트맵 (Heatmap)



Key Insight:

단일 변수 비교는 정보가 제한적이다.

두 변수를 결합해 평균 구매금액의 상대적 차이가 어디에서 어디에서 나타나는지 한 눈에 확인한다.

히트맵은 조합별 평균이 높아지는 구간을 빠르게 찾게 해준다.

한방에 보는 그룹화 TOP 3

누가 평균적으로 더 많이 지출했는가? (Exploratory Signal)

Gender

M (Mean: 9437) > F (Mean: 8734)

Age

51-55 (Mean: 9534) > 55+ (Mean: 9336)

City

C (Mean: 9719) > B (Mean: 9151) > A (Mean: 8911)


Occupation

Occ_17 (Mean: 9821) is highest




주의: Count(표본 수)도 같이 봐서 너무 작은 집단의 착시를 피해야 한다.
Median(중앙값)을 확인하여 평균이 이상치에 끌려 올라갔는지 확인해야 한다.

수치형 변수 간 관계: 상관계수 (Correlation)



해석: 수치형 변수들끼리 '같이 움직이는 정도'가 매우 낮다. 상관계수 히트맵이 대부분 어두운 색(0에 가까움)을 띤다. 따라서 선형 회귀보다는 범주형 변수 기반의 세그먼트 분석이 더 유효함을 시사한다.



범주형 변수 간 관계: Cramér's V

변수 간 중복성(Multicollinearity) 확인

Top Associated Pairs	
1.	Age x Occupation: $V=0.424$ (Strongest association)
2.	Age x Marital_Status: $V=0.344$
3.	Gender x Occupation: $V=0.275$

해석

Cramér's V값이 높은 쌍은 '변수끼리 분포가 엮여' 있다는 의미다.

예: Age와 Occupation이 강하게 연결되어 있으면, Purchase 영향이 '나이 때문인지, 직업 때문인지' 해석이 곱칠 수 있다.

교차분석으로 분리해 보는 것이 안전하다.

핵심 결론: 변수 중요도 분석 (Correlation Ratio η)

어떤 변수가 구매금액을 가장 잘 설명하는가?

Variable Importance (η)

Variable	η Value (Importance)
Product_Category	$\eta = 0.797$ (Dominant Factor)
City_Category	$\eta = 0.063$
Gender	$\eta = 0.060$
Occupation	$\eta = 0.059$
Age	$\eta = 0.021$
Stay_Years	$\eta = 0.008$

결론

Product_Category($\eta=0.79$)가 압도적으로 구매금액 차이를 잘 설명한다.

나머지 인구통계 변수들은 단독으로 구매금액을 가르는 힘이 약하다 (0.07 미만).

타겟팅의 출발점은 반드시 '제품
'제품 카테고리'여야 한다.

변수 단위 상세 요약 (Automated Insights)

평균 대비 상승률 (Lift Analysis)

City

City C

(Mean 9,720)

is **+4.9%** vs
Avg.

Occupation

Group 17

(Mean 9,821)

is **+6.0%** vs
Avg.

Age

Group 51-55

(Mean 9,535)

is **+2.9%** vs
Avg.

Gender

Male

(Mean 9,438)

is **+1.9%** vs
Avg.

Note: 특정 그룹(City C, Age 51-55)이 평균보다 높게 나타나지만, 낮은 Eta 값을 고려할 때 이는 강력한 분리기준이라기보다 미세한 'Nudge'로 해석해야 한다.

종합 결론 및 실무 제언 (Final Conclusion & Strategy)

종합 결론 (Key Conclusions)

	City_Category	Stay_In_Current_City_Years	Product_Category
1	통계적으로 유의미한 차이가 있으나, 큰 격차보다는 유형 간 패턴 차이로 해석하는 것이 적절하다.	구매금액 수준을 강하게 설명하지 않는다. 단독 타겟팅 변수보다는 보조 변수로 쓰는 편이 맞다.	고객 구성 차이가 존재하며, 구매금액을 설명하는 가장 강력한 변수($\eta=0.79$)이다.

실무 적용: 단일 변수 기반의 단순 세분화보다 **City_Category x Product_Category** 같은 교차 세그먼트로 접근하는 방향이 더 설득력 있다.

후속 분석 제안: 상위 구매금액 구간(예: 상위 10%)을 정의해 고액 구매 패턴 별도 분석.